

NetAnalysisys

Анализ структуры и приближённых расстояний
в больших графах

Санкт-Петербургский государственный университет
«Теория графов и её приложения», 2026

Команда №3

Преподаватель: Воронкова Е. Б.

Постановка задачи

Проблема: Графы социальных сетей содержат миллионы вершин и сотни миллионов рёбер. Точный расчёт кратчайших путей (APSP) непрактичен.

Три цели проекта

1. Разработать инструмент для структурного анализа графов — связность, кластеризация, устойчивость
2. Реализовать и сравнить Landmark-алгоритмы оценки расстояний (Basic LM, BFS LM) с 3 стратегиями выбора ориентиров
3. Провести эксперименты на 13 датасетах — от 889 до ~3M вершин

Ключевые исследовательские вопросы

- Как устроена топология реальных сетей?
- Каков trade-off между скоростью и точностью landmark-алгоритмов?
- Какая стратегия выбора ориентиров оптимальна?

Архитектура NetAnalysis

Технологический стек:

Rust (stable)

crossterm TUI

tokio

rayon

Модули

- `graph/` — списки смежности, маппинг ID, степени
- `parser/` — .txt / .csv / .mtx, автоопределение directed/undirected
- `analysis/` — 6 подмодулей: связность → степени → диаметр → треугольники → кластеризация → устойчивость
- `landmarks/` — Basic LM + BFS LM, 3 стратегии выбора
- `ui/` — TUI-меню, файловый браузер, анимация
- `interactive_landmarks/` — запрос расстояний, accuracy- и speed-бенчмарки

Pipeline обработки

Датасеты

13 графов, 3 категории — широкий охват предметных областей

Категория	Кол-во	Диапазон вершин	Примеры
Directed			
Undirected	5	889 – 1.7M	ca-coauthors-dblp, CA-GrQc, CA-AstroPh, musae-git-edges, ca-HepTh
Large			

От коллабораций учёных → веб-графы → социальные сети → мессенджеры.

Pipeline анализа и вычисляемые метрики

Блок 1. Базовая статистика

- $|V|$, $|E|$, плотность
- Weak / Strong компоненты
- LWCC / LSCC

Блок 2. Степени

- min / max / avg degree
- Распределение степеней
- Regular + log-log шкалы

Блок 3. Диаметр

- Double BFS
- Random 500 BFS
- Snowball sampling
- 90-й перцентиль

Degree
distribution

Log-log
degree
distribution

Блок 4. Треугольники и кластеризация

- Полный подсчёт треугольников
- Средний коэффициент
- Глобальный коэффициент

Блок 5. Устойчивость

- Random removal (5%–100%)
- Degree-targeted removal
- Доля вершин в giant component

Визуализация

- PNG-графики распределений
- Терминальные графики
- Интерактивные запросы

Базовая статистика графов

Все графы крайне разрежены: density $\sim 10^{-5} \dots 10^{-3}$

Параметр	Undirected (mean $\pm \sigma$)	Directed (mean $\pm \sigma$)	Large (mean)
Density			
LWCC	0.937 ± 0.098	0.975 ± 0.046	1.000
LSCC			
Avg Degree	24.59 ± 22.17	15.28 ± 10.15	5.265
Diameter (DBFS)			

Ключевой инсайт: у directed-графов слабая связность высока (LWCC ~ 0.97), но сильная — крайне низкая (LSCC ~ 0.22). Разрыв LWCC – LSCC ≈ 0.75 .

Outlier: soc-wiki-Vote — LSCC ≈ 0.001 (сильная компонента практически отсутствует).

Кластеризация и треугольники

Диапазон clustering coefficient — от 0.08 до 0.80.

Граф	Треугольники	Avg CC	Global CC	Тип
ca-coauthors-dblp				
Wiki-vote / soc-wiki-Vote	Умеренное	0.15–0.25	Низкий	Локальные кластеры без глобального замыкания
web-NotreDame / youtube				

Clustering — маркер типа сети: высокий → community-heavy, низкий → hub-dominated.

Устойчивость к удалению вершин

Два сценария: random removal vs degree-targeted removal

Граф	Random (50% удалено)	Targeted (50% удалено)	Характер
ca-coauthors			
musae-git-edges	Giant comp. сохранена	Быстрый распад	Выраженная hub-архитектура
web-Stanford			
web-NotreDame	Giant comp. сохранена	Экстремально быстрый коллапс	Экстремальный hub-dominance

Вывод: все графы — hub-driven / scale-free. Случайное удаление разрушает медленно, удаление хабов — резкий перколяционный порог.

Типология исследованных графов

4 типа на основе метрик:

Тип	Представители	Признаки
Community-heavy		
Hub-dominated	musae-git-edges, web-Stanford, web-NotreDame, youtube	Низкая плотность, большой k_max, быстрая потеря связности при targeted removal
Фрагментированные		
Асимметричные directed	soc-wiki-Vote, wiki-Vote	Огромный разрыв weak ↔ strong connectivity; направление сильно ограничивает достижимость

Landmark-алгоритмы: постановка задачи

Зачем нужны landmarks?

Точный BFS на графе с 3М вершин и 117М рёбер — 1.26–1.57 с на один запрос. Для тысячи запросов — часы.

Идея: выбрать k ориентиров (landmarks), предпосчитать расстояния от них, оценивать расстояние между любыми двумя вершинами через ориентиры за $O(k)$.

Два алгоритма

- **Basic LM:** $d(s,t) \approx \min_l [d(s,l) + d(l,t)]$
- **BFS LM:** сохраняем BFS-деревья, на запросе строим подграф пересечения путей $\rightarrow$ BFS

Три стратегии выбора

1. **Random** — случайный выбор
2. **Highest-degree** — вершины с максимальной степенью
3. **Farthest-first coverage** — максимальное геодезическое покрытие

Landmark: архитектура реализации

LandmarkSelection (enum)

- └ Random
- └ HighestDegree
- └ Coverage (farthest-first)

LandmarkBasic

- └ precompute()
 - └ BFS от каждого LM
- └ estimate(s, t)
 - └ $\min(d(s, LM) + d(LM, t))$

LandmarkBFS

- └ precompute()
 - └ BFS + parent tree
- └ estimate(s, t)
 - └ collect_subgraph(s→LM + t→LM)
 - BFS на подграфе

Характеристика	Basic LM	BFS LM
Precomputation		
Запрос	$O(k)$	$O(\text{subgraph})$

Landmark: скорость на большом графе (~1.5 GB)

Условия: ~10 и ~100 landmarks, 50 случайных пар, 3 стратегии

Метод	10 LM (avg, μ s)	100 LM (avg, μ s)	Ускорение vs Exact
Exact BFS			
Basic LM	~3.8	~1600	$\times 400\,000 \rightarrow \times 1\,000$
BFS LM			

- Basic LM ускоряет exact BFS в 400 000 раз (10 LM) и в 1 000 раз (100 LM)
- BFS LM — компромисс: $\times 80$ – 100 быстрее exact, но точнее Basic
- Рост LM с 10 до 100 $\rightarrow$ Basic LM замедляется в ~ 500 раз — trade-off очевиден

Landmark: скорость на малом графе (Wiki-Vote)

Условия: Wiki-Vote (~7K вершин), 300 случайных пар

Метод	10 LM (avg, μ s)	100 LM (avg, μ s)	vs Exact
Exact BFS			
Basic LM	~2.1	~7.5	$\times 200 \rightarrow \times 56$
BFS LM			

Критический вывод: на маленьких графах BFS LM теряет смысл как ускоритель — overhead precomputation + построение подграфа дороже, чем просто запустить exact BFS.

Landmark: точность

Большой граф (50 пар)

Параметр	Basic LM	BFS LM
Exact-match rate (10 LM)		
Exact-match rate (100 LM)	48–58%	74–88%
Средняя ошибка (10 LM)		
Средняя ошибка (100 LM)	0.6–0.9	0.2–0.4

Wiki-Vote (300 пар)

Параметр	Basic LM	BFS LM
Exact-match rate (10 LM)		
Exact-match rate (100 LM)	28–34%	85–100%
Средняя ошибка (10 LM)		
Средняя ошибка (100 LM)	0.8–1.2	0.0–0.2

Закономерности:

- BFS LM стабильно точнее Basic LM
- Увеличение LM с 10 → 100 резко повышает точность (BFS LM: 28–48% → 74–88%)
- На малом графе BFS LM достигает 100% совпадения с exact — идеальная точность

Landmark: влияние стратегий выбора

На большом графе (~1.5 GB)

- **Random**: хороший baseline, конкурентен для BFS LM
- **Highest-degree**: самая сбалансированная для Basic LM — лучший exact-match rate, ниже ошибка
- **Farthest-first**: не универсальный лидер — иногда уступает degree по accuracy

На малом графе (Wiki-Vote)

- **Highest-degree**: стабильна, хороша по accuracy
- **Farthest-first**: лучшая latency для Basic LM, но по точности не всегда выигрывает
- **Random**: приемлема, но не оптимальна

Статистическая оговорка: на 50 парах разница 44% vs 48% — шум. Разница 0% vs 58% или 28% vs 85% — реальный эффект. На 300 парах выводы надёжнее.

Практические рекомендации

Если ваша цель	Алгоритм	Стратегия	k
Максимальная скорость			
Максимальная точность	BFS LM	Highest-degree	100
Баланс			
Маленький граф (< 50K)	Exact BFS	—	—
Low-latency на малом графе			

Правило большого пальца:

- Basic LM: взрывная скорость, умеренная точность
- BFS LM: высокая точность, хорошее ускорение (кроме малых графов)
- Degree-based — самая устойчивая стратегия в большинстве сценариев

Заключение

Что сделано

- Разработано Rust TUI-приложение для полного цикла анализа графов
- Реализованы 3 метода оценки диаметра + 2 landmark-алгоритма + 3 стратегии
- Проведены эксперименты на 13 датасетах

Перспективы

CI/CD

Тестовое покрытие

Библиотечный crate

WebAssembly

Ключевые выводы

1. Реальные графы — **scale-free** с hub-архитектурой; directed — проблема сильной связности
2. Basic LM: до $4 \times 10^5 \times$ ускорение, точность 0–58%
3. BFS LM: до 80–88% точности при 100 LM, $\times 80$ –100
4. Degree-based — самая устойчивая стратегия
5. BFS LM на малых графах теряет смысл

NetAnalisisys

Мороз Владислав • Овечкин Андрей
Команда №3 • СПбГУ • 2026

© 2026 Moroz Vladislav, Ovechkin Andrey.

All content in this presentation is licensed under the
Creative Commons Attribution-ShareAlike 4.0 International
(CC BY-SA 4.0)

<https://creativecommons.org/licenses/by-sa/4.0/>