

NetAnalysis

Анализ структуры и приближённых расстояний
в больших графах

Группа 25Б72-мм • Команда №3
Санкт-Петербургский государственный университет
2026

Постановка задачи

Проблема: Графы социальных сетей содержат миллионы вершин и сотни миллионов рёбер. Точный расчёт кратчайших путей (APSP) непрактичен.

Три цели проекта

1. Разработать инструмент для **структурного анализа графов** — связность, кластеризация, устойчивость
2. Реализовать и сравнить **Landmark-алгоритмы оценки расстояний** (Basic LM, BFS LM) с 3 стратегиями выбора ориентиров
3. Провести эксперименты на **13 датасетах** — от 889 до ~3М вершин

Ключевые исследовательские вопросы

- Как устроена **топология реальных сетей**?
- Каков **trade-off между скоростью и точностью** landmark-алгоритмов?
- Какая **стратегия выбора ориентиров** оптимальна?

Архитектура

Архитектура NetAnalisys

Технологический стек:

Rust (stable)

crossterm TUI

tokio

rayon

Модули

- `graph/` — списки смежности, маппинг ID, степени
- `parser/` — .txt / .csv / .mtx, автоопределение directed/undirected
- `analysis/` — 6 подмодулей: связность → степени → диаметр → треугольники → кластеризация → устойчивость

Интерфейс

- `landmarks/` — Basic LM + BFS LM, 3 стратегии выбора
- `ui/` — TUI-меню, файловый браузер
- `interactive_landmarks/` — запрос расстояний, accuracy- и speed-бенчмарки

Pipeline обработки

выбор датасета → парсинг → параллельный подсчёт метрик → вывод + PNG → интерактивный режим

Pipeline diagram

Датасеты

13 графов, 3 категории — широкий охват предметных областей

Категория	Кол-во	Диапазон вершин	Примеры
Directed	5	7K – 876K	web - Google, web - Stanford, wiki - Vote, soc - wiki - Vote, web - NotreDame
Undirected	5	889 – 1.7M	ca - coauthors - dblp, CA - GrQc, CA - AstroPh, musae - git - edges, ca - HepTh
Large	3	1.1M – 2.99M	youtube, vk, livejournal

От коллабораций учёных → веб-графы → социальные сети → мессенджеры.

Результаты анализа

Pipeline анализа и вычисляемые метрики

Блок 1. Базовая статистика

- $|V|$, $|E|$, плотность
- Weak / Strong компоненты
- LWCC / LSCC

Блок 4. Треугольники и кластеризация

- Полный подсчёт треугольников
- Средний коэффициент
- Глобальный коэффициент

Блок 2. Степени

- min / max / avg degree
- Распределение степеней
- Regular + log-log шкалы

Блок 5. Устойчивость

- Random removal (5%–100%)
- Degree-targeted removal
- Доля вершин в giant component

Блок 3. Диаметр

- Double BFS
- Random 500 BFS
- Snowball sampling
- 90-й перцентиль

Визуализация

- PNG-графики распределений
- Терминальные графики
- Интерактивные запросы

Degree distribution

Log-log degree distribution

Базовая статистика графов

Все графы крайне разрежены: density $\sim 10^{-5} \dots 10^{-3}$

Параметр	Undirected (mean $\pm \sigma$)	Directed (mean $\pm \sigma$)	Large
Density	0.00067 $\pm$ 0.00050	0.00151 $\pm$ 0.00171	0.000407
LWCC	0.937 $\pm$ 0.098	0.975 $\pm$ 0.046	1.000
LSCC	—	0.221 $\pm$ 0.224	—
Avg Degree	24.59 $\pm$ 22.17	15.28 $\pm$ 10.15	5.265
Diameter (DBFS)	16.25 $\pm$ 5.12	12.0 $\pm$ 21.4	24

Ключевой инсайт: у directed-графов слабая связность высока (**LWCC ~ 0.97**), но сильная — крайне низкая (**LSCC ~ 0.22**). Разрыв LWCC – LSCC ≈ 0.75 .

Outlier: soc-wiki-Vote — LSCC ≈ 0.001 (сильная компонента практически отсутствует).

Кластеризация и треугольники

Диапазон clustering coefficient — от 0.08 до 0.80.

Граф	Треугольники	Avg CC	Global CC	Тип	
ca-coauthors-dblp	Гигантское число	0.80	0.08 (при 1.7М вершин)	Плотная сообщественная структура	
Wiki-vote / soc-wiki-Vote	Умеренное	0.15–0.25	Низкий	Локальные кластеры без глобального замыкания	
web-NotreDame / youtube	Низкое	Низкий	Низкий	Разреженная backbone-структура	

Clustering — маркер типа сети: высокий → community-heavy, низкий → hub-dominated.

Устойчивость к удалению вершин

Два сценария: random removal vs degree-targeted removal

Граф	Random (50% удалено)	Targeted (50% удалено)	Характер
ca-coauthors	Giant comp. сохранена	Медленная деградация, затем резкий обвал	Умеренная hub-зависимость
musae-git-edges	Giant comp. сохранена	Быстрый распад	Выраженная hub-архитектура
web-Stanford	Giant comp. сохранена	Резкий пороговый распад	Сильная hub-архитектура
web-NotreDame	Giant comp. сохранена	Экстремально быстрый коллапс	Экстремальный hub-dominance

Вывод: все графы — hub-driven / scale-free. Случайное удаление разрушает медленно, удаление хабов — резкий перколяционный порог.

Типология исследованных графов

4 типа на основе метрик:

Тип	Представители	Признаки
Community - heavy	ca - coauthors - dblp, wiki - Vote, soc - wiki - Vote	Высокий clustering, много треугольников, небольшой диаметр, чувствительность к хабам
Hub - dominated	musae - git - edges, web - Stanford, web - NotreDame, youtube	Низкая плотность, большой k_max, быстрая потеря связности при targeted removal
Фрагментированные	CA - GrQc, CA - AstroPh	Много weak components, но giant WCC доминирует; неоднородная структура
Асимметричные directed	soc - wiki - Vote, wiki - Vote	Огромный разрыв weak ↔ strong connectivity; направление сильно ограничивает достижимость

Landmark-алгоритмы

Landmark-алгоритмы: постановка задачи

Зачем нужны landmarks?

Точный BFS на графе с **3M** вершин и **117M** рёбер — **1.26–1.57 с** на один запрос. Для тысячи запросов — часы.

Идея: выбрать **k ориентиров** (landmarks), предпосчитать расстояния от них, оценивать расстояние между любыми двумя вершинами через ориентиры за **O(k)**.


Два алгоритма

- **Basic LM:** $d(s,t) \approx \min_l [d(s,l) + d(l,t)]$
- **BFS LM:** сохраняем BFS-деревья, на запросе строим подграф пересечения путей $\rightarrow$ BFS

Три стратегии выбора

1. **Random** — случайный выбор
2. **Highest-degree** — вершины с максимальной степенью
3. **Farthest-first coverage** — максимальное геодезическое покрытие

Landmark: архитектура реализации



Landmark: скорость на большом графе (~1.5 GB)

Условия: ~10 и ~100 landmarks, 50 случайных пар, 3 стратегии

Метод	10 LM (avg, μs)	100 LM (avg, μs)	Ускорение vs Exact
Exact BFS	~1 570 000	~1 570 000	1×
Basic LM	~3.8	~1 600	×400 000 → ×1 000
BFS LM	~19 500	~18 500	×80 → ×85

- Basic LM ускоряет exact BFS в **400 000 раз** (10 LM) и в **1000 раз** (100 LM)
- BFS LM — компромисс: **×80–100** быстрее exact, но точнее Basic
- Рост LM с 10 до 100 → Basic LM замедляется в ~500 раз — **trade-off очевиден**

Landmark: скорость на малом графе (Wiki-Vote)

Условия: Wiki-Vote (~7K вершин), 300 случайных пар

Метод	10 LM (avg, μs)	100 LM (avg, μs)	vs Exact
Exact BFS	~420	~420	1×
Basic LM	~2.1	~7.5	×200 → ×56
BFS LM	~6 800	~8 200	Медленнее!

Критический вывод: на маленьких графах BFS LM теряет смысл как ускоритель — overhead precomputation + построение подграфа дороже, чем просто запустить exact BFS.

Landmark: точность

Большой граф (50 пар)

Параметр	Basic LM	BFS LM
Exact-match rate (10 LM)	0–6%	28–48%
Exact-match rate (100 LM)	48–58%	74–88%
Средняя ошибка (10 LM)	1.8–2.5	0.8–1.2
Средняя ошибка (100 LM)	0.6–0.9	0.2–0.4

Wiki-Vote (300 пар)

Параметр	Basic LM	BFS LM
Exact-match rate (10 LM)	0–10%	42–58%
Exact-match rate (100 LM)	28–34%	85–100%
Средняя ошибка (10 LM)	2.0–3.0	0.7–1.0
Средняя ошибка (100 LM)	0.8–1.2	0.0–0.2

Закономерности:

- BFS LM стабильно точнее Basic LM
- Увеличение LM с 10 → 100 резко повышает точность (BFS LM: **28–48% → 74–88%**)
- На малом графе BFS LM достигает **100% совпадения** с exact — идеальная точность

Landmark: влияние стратегий выбора

На большом графе (~1.5 GB)

- **Random:** хороший baseline, конкурентен для BFS LM
- **Highest-degree:** самая сбалансированная для Basic LM — лучший exact-match rate, ниже ошибка
- **Farthest-first:** не универсальный лидер — иногда уступает degree по accuracy

На малом графе (Wiki-Vote)

- **Highest-degree:** стабильна, хороша по accuracy
- **Farthest-first:** лучшая latency для Basic LM, но по точности не всегда выигрывает
- **Random:** приемлема, но не оптимальна

Статистическая оговорка: на 50 парах разница 44% vs 48% — шум. Разница 0% vs 58% или 28% vs 85% — реальный эффект. На 300 парах выводы надёжнее.

Практические рекомендации

Если ваша цель	Алгоритм	Стратегия	k
Максимальная скорость	Basic LM	Random / Farthest - first	10
Максимальная точность	BFS LM	Highest - degree	100
Баланс	BFS LM	Highest - degree	30–50
Маленький граф (< 50K)	Exact BFS	—	—
Low-latency на малом графе	Basic LM	Farthest - first	10

Правило большого пальца: Basic LM — взрывная скорость, умеренная точность. BFS LM — высокая точность, хорошее ускорение (кроме малых графов). Degree-based — самая устойчивая стратегия в большинстве сценариев.

Заключение

Заключение

Что сделано

- Разработано **Rust TUI-приложение** для полного цикла анализа графов
- Реализованы **3 метода оценки диаметра** + **2 landmark-алгоритма** + **3 стратегии**
- Проведены эксперименты на **13 датасетах**

Перспективы

CI/CD

Тестовое покрытие

Библиотечный crate

WebAssembly

Ключевые выводы

1. Реальные графы — **scale-free** с hub-архитектурой; directed — проблема сильной связности
2. **Basic LM**: до **$4 \times 10^5 \times$** ускорение, точность 0–58%
3. **BFS LM**: до **80–88%** точности при 100 LM, $\times 80$ –100
4. **Degree-based** — самая устойчивая стратегия
5. BFS LM на малых графах теряет смысл

NetAnalisisys

Мороз Владислав • Овечкин Андрей
Группа 25Б72-мм • Команда №3 • 2026

© 2026 Moroz Vladislav, Ovechkin Andrey.
All content in this presentation is licensed under the
(CC BY-SA 4.0)

<https://creativecommons.org/licenses/by-sa/4.0/>